

Predicción del precio del oro en Colombia con regímenes macroeconómicos, UMAP y modelos de aprendizaje de maquin



Presentación final del
proyecto

Análisis estructural + capa predictiva +
simulación de estrategias

Contexto Colombia + contexto global
auxiliar

Sergio Alejandro Gil Rios
Jerónimo Novoa Giraldo
Alejandro Londoño Correa

Grupo de Investigación GCPDS · Teoría de Aprendizaje de
Máquinas
Docente: Diego Armando Pérez Rosero



Modelo final:
HistGradientBoostingClassifi
er

Problema, objetivo y pregunta de investigación.

Datos, tratamiento y advertencia metodológica sobre la frecuencia efectiva del oro.


Capa determinística/estructural: UMAP, clustering, local biplot, periodo presidencial y enfermedad holandesa.

Capa predictiva: comparación de modelos, validación walk-forward y calibración de umbral.

Interpretabilidad, desempeño por regímenes y simulación de estrategias de inversión.

Conclusiones, limitaciones y siguientes pasos para dashboard y documento final.

Arquitectura metodológica: Colombia como núcleo, contexto global como capa auxiliar



Pipeline metodológico resumido del proyecto.

Problema

**¿Es posible explicar
y anticipar la
dirección del oro?**

Usando información macroeconómica, energética y de mercados

Objetivo

**Construir una
arquitectura
interpretable**

Que combine regímenes estructurales y modelos predictivos

Pregunta central

**¿Los regímenes
detectables mejoran
la predicción?**

Y permiten comparar contextos presidenciales y de organismos internacionales

La hipótesis principal es que el precio del oro no depende solo de su propia memoria, sino también del entorno cambiario, monetario, energético, de commodities y de regímenes macroeconómicos.

La propuesta separa el problema en dos capas: una capa estructural no supervisada, y una capa supervisada para dirección y magnitud del retorno futuro.

El foco del proyecto se mantiene en la base Colombia; el contexto global se incorpora como apoyo explicativo y predictivo, sin perder interpretabilidad.

Base diaria Colombia

9.283 filas

2000-01-01 a 2025-05-31

Variables base

11 series

Oro, TRM, TIPM, Brent, café, DTF,
etc.

Contexto global auxiliar

**91 columnas
homogenizadas**

ETFs, futuros, índices de dólar, bolsas
y tasas externas

BD EH

27 años

Indicadores estructurales
anuales

Espacio final

**≈ 2.304
features**

Tras rezagos, ventanas y
transformaciones

Tratamiento: normalización de fechas, sanitización de variables, coerción numérica, rezagos, retornos logarítmicos, diferencias, medias móviles y volatilidades.

La base anual de enfermedad holandesa se alinea por año y se utiliza principalmente como contexto rezagado, evitando fuga de información.

Se preserva una trazabilidad explícita del preprocesamiento para el dashboard y la documentación final.



Advertencia metodológica

importante
Aunque la base es diaria, el precio del oro presenta solo ~305 valores únicos.

Eso sugiere una frecuencia efectiva cercana a mensual.

Por ello, el horizonte de 21 días se vuelve más coherente que horizontes muy cortos, y la interpretación diaria debe hacerse con cautela.


Se trabajaron dos vistas: valores absolutos (régimen macrohistórico) y cambios diarios (familias de shock).




Las corridas profundas previas mostraron que las configuraciones 6/7 eran las más consistentes con la semántica de regímenes y enfermedad holandesa.

El cuaderno final conserva esa lógica estructural y reutiliza los mejores regímenes como variables explicativas.



La optimización se apoya en silhouette para escoger configuraciones con separación e interpretabilidad razonables.



(a) Clusters en valores absolutos




(b) Clusters en cambios diarios




UMAP permite representar la geometría de vecindad de las observaciones en 2D.

KMeans segmenta el embedding y el local biplot ayuda a interpretar qué variables dominan localmente cada grupo.

En la práctica, la vista en niveles resume regímenes históricos; la vista en cambios resume shocks de corto plazo.




(a) Local biplot en valores absolutos




(b) Local biplot en cambios diarios


Capa estructural III: asociación con periodo presidencial y enfermedad holandesa




(a) Periodo presidencial



(b) Enfermedad holandesa



(a) Periodo presidencial




(b) Enfermedad holandesa

Los clusters en valores absolutos se asocian con los periodos presidenciales y, en menor grado, con la clasificación de enfermedad holandesa.

Esto respalda la idea de que la capa no supervisada captura una estructura macrohistórica real y no solo una separación geométrica arbitraria.

En contraste, los clusters de cambios diarios apenas se ordenan por gobierno o enfermedad holandesa, lo cual es consistente con la idea de “shocks” de corto plazo.


Estas etiquetas estructurales se incorporan después a la fase supervisada como variables y como ejes de segmentación del desempeño.




En otras palabras: la parte determinística no se deja aislada; se convierte en variables y segmentos con valor predictivo.

Esto permite interpretar mejor dónde el modelo funciona, dónde falla y qué regímenes son más predecibles.


Top 20 modelos walk-forward h21



Mejor configuración por feature set



Mejor desempeño por ventana temporal



La comparación evidencia el aporte del set Colombia + contexto global y la importancia de una validación temporal adecuada.

Modelo

HistGradientBoostingClassifier

Horizonte = 21 días

Feature set

**colombia
plus
global**

Regime version =
upnp-k6-7-structural

Train window

all

Weight = balanced

BACC

87.3%




Acc



88.8%

ROC-AUC

0.948

Threshold = 0.310








La clasificación define si el precio tendería a subir o no subir en 21 días.

La regresión de magnitud estima cuánto podría variar el retorno esperado, complementando la señal direccional.

Esta combinación es clave para el simulador de inversión del dashboard.



Las variables asociadas al oro, la demanda energética, el café, Brent, TRM y señales estructurales aparecen reiteradamente como relevantes.





Lectura principal

Periodo Petro: accuracy 90.1%, balanced accuracy 90.3%, AUC 0.954.

Periodo Duque: accuracy 87.2%, balanced accuracy 87.7%, AUC 0.946.


El modelo no rinde igual en todos los segmentos; la predictibilidad depende del régimen macroeconómico.

Esta heterogeneidad justifica la incorporación explícita de clústeres, postura monetaria y enfermedad holandesa como ejes del análisis.



El análisis determinístico no se reemplaza; se usa como capa interpretativa y como referencia para evaluar el valor agregado de la IA.

Los mejores modelos superan las reglas simples y, además, entregan probabilidades y señales de magnitud útiles para simulación.



Ejemplos del backtest sin costos

Buy & hold: capital final $\approx$ \$1,847,233; retorno total $\approx$ 84.7%.

Clasificador long/cash: capital final $\approx$ \$2,171,661; CAGR $\approx$ 32.9%.

Clasificador long/short: capital final $\approx$ \$2,542,779; retorno total $\approx$ 154.3%.

Predicción de retorno long/short: capital final $\approx$ \$2,530,903; retorno total $\approx$ 153.1%.

Estas estrategias sirven como base conceptual para el módulo de simulación del dashboard.

Módulo 1

Exploración de datos

Cobertura, preprocesamiento y trazabilidad

Módulo 2

Regímenes económicos

UMAP, clusters, local biplot y transiciones

Módulo 3

Comparación de modelos

Métricas, thresholds y salidas

Módulo 4

Predicción operativa

Sube / no sube + magnitud esperada

Módulo 5



Simulador

Backtest e inversión

Visualización del comportamiento por periodo presidencial, clusters y enfermedad holandesa.

Comparación entre modelos Colombia-only y Colombia + contexto global.

Gráficas de retorno real vs estimado, precio esperado y probabilidades del modelo.



El proyecto logró integrar de forma coherente una capa estructural interpretable con una capa predictiva de mejor desempeño.

El mejor clasificador final fue HistGradientBoostingClassifier con feature set colombia_plus_global_full, horizonte de 21 días, balanced accuracy de 87.3% y ROC-AUC de 0.948.

Los regímenes extraídos por UMAP/KMeans no son un adorno: ayudan a explicar el fenómeno, segmentar el desempeño y enriquecer la predicción.

El contexto global aporta valor, pero el eje del proyecto sigue siendo la base Colombia y su lectura en términos presidenciales, monetarios y de enfermedad holandesa.

La salida actual ya alimenta el documento técnico, el dashboard y la sustentación final.

Como siguiente paso, conviene afinar el dashboard, incorporar costos de transacción al simulador y probar versiones especializadas por régimen.

Mensaje final: el proyecto no es solo un predictor del oro; es una arquitectura analítica para estudiar el oro en Colombia desde una perspectiva económica, estructural y predictiva.